

PROYECTO TELECOMX

Prediccion de Abandono de Clientes (Churn) con Machine Learning

Documentacion Completa de Pasos, Skills y Prompts

Resumen del Proyecto

Este documento detalla todos los pasos realizados en el desarrollo del modelo de prediccion de Churn para TelecomX, incluyendo los skills de IA utilizados y los prompts exactos empleados en cada etapa. El modelo final (Random Forest Optimizado) alcanzo un Recall de 89% y AUC de 0.841.

PASO 01 Configuracion del Entorno y Skills

Skills utilizados: token-optimizer | context-window-management | compress-prompt | sequential-thinking

Descripcion:

Se configuraron los skills de optimizacion de tokens y razonamiento para maximizar la eficiencia durante todo el proyecto.

Prompt utilizado en Claude Code:

Activa token-optimizer, context-window-management y compress-prompt para esta sesion. Usa sequential-thinking para planificar el analisis completo del proyecto TelecomX.

PASO 02 Validacion de Calidad de Datos

Skills utilizados: data-analysis | read-file | sequential-thinking

Descripcion:

Se cargo el DataFrame de ventas y se realizo un informe completo de calidad de datos incluyendo tipos de variables, nulos, duplicados, estadisticas descriptivas y outliers.

Prompt utilizado en Claude Code:

Usa read-file para cargar df_ventas. Luego usa data-analysis y sequential-thinking para validar la calidad de datos con: 1. Tipos de cada variable (dtypes) 2. Valores nulos (cantidad y porcentaje por columna) 3. Duplicados (filas completas y por columna clave) 4. Estadisticas descriptivas (media, mediana, std, min, max, percentiles) 5. Outliers (IQR y z-score) 6. Cardinalidad de variables categoricas 7. Rango de fechas si hay columnas temporales Al finalizar genera un informe completo de calidad de datos en markdown.

PASO 03 Analisis Exploratorio de Datos (EDA) - Graficos

Skills utilizados: data-analysis-jupyter | sequential-thinking | data-analysis | statistics-math

Descripcion:

Se realizo un EDA completo con graficos separados por celdas usando seaborn: series temporales, ventas por dia/categoria/subcategoria, top productos y densidad de precios.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking para planificar y luego data-analysis-jupyter para ejecutar un EDA completo en celdas separadas de Jupyter usando seaborn. CELDA 1: Series temporales por ano con marcas de Black Friday CELDA 2: Ventas por dia de la semana CELDA 3: Ventas por categoria CELDA 4: Ventas por subcategoria (top 15) CELDA 5: Top 20 productos CELDA 6: Densidad KDE comparando precios propios vs Amazon Estilo seaborn-v0.8-darkgrid, paleta 'husl', figsize=(14,6)
```

PASO 04 Ingenieria de Caracteristicas

Skills utilizados: pandas-data-analysis | data-analysis-jupyter | sequential-thinking | clean-code

Descripcion:

Se convirtieron variables categoricas binarias a formato numerico (1/0) y se aplico One-Hot Encoding a variables multiclase como Contract y PaymentMethod.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking, pandas-data-analysis y data-analysis-jupyter para hacer ingenieria de caracteristicas en celdas separadas: CELDA 1: Conversion de variables binarias (Si/No -> 1/0) CELDA 2: One-Hot Encoding con pd.get_dummies(drop_first=True) CELDA 3: Validacion de dtypes finales y shape antes/después Usar clean-code para encapsular en funciones reutilizables.
```

PASO 05 Analisis de Correlacion con Variable Churn

Skills utilizados: statistics-math | data-analysis-jupyter | pandas-data-analysis | sequential-thinking

Descripcion:

Se identificaron los factores con mayor correlacion con la variable objetivo Churn mediante matriz de correlacion, heatmaps, analisis por variables categoricas y numericas.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking, statistics-math, pandas-data-analysis y data-analysis-jupyter para analizar la correlacion con Churn en celdas separadas: CELDA 1: Heatmap de matriz de correlacion (annot=True, cmap='coolwarm') CELDA 2: Top 10 variables correlacionadas con Churn (barras horizontal) CELDA 3: Tasa de Churn por Contract y PaymentMethod CELDA 4: Boxplots MonthlyCharges, tenure, TotalCharges vs Churn CELDA 5: Conclusiones estadisticas y recomendaciones
```

PASO 06 Visualizacion Exploratoria Churn vs No Churn

Skills utilizados: data-analysis-jupyter | statistics-math | sequential-thinking | data-analysis

Descripcion:

Se crearon graficos de densidad y distribucion para visualizar el comportamiento de clientes que abandonan frente a los que permanecen.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking, statistics-math y data-analysis-jupyter para crear visualizaciones comparando Churn=1 vs Churn=0 en celdas separadas: CELDA 1: Distribucion general de Churn (barras + pie chart) CELDA 2: KDE plots de MonthlyCharges, TotalCharges, tenure CELDA 3: Countplots por Contract, PaymentMethod, InternetService CELDA 4: Boxplots comparativos MonthlyCharges, tenure, TotalCharges CELDA 5: Violin plots de tenure por Churn y Contract CELDA 6: Pairplot con hue='Churn'
```

PASO 07 Preparacion del Modelo y Modelo Base

Skills utilizados: machine-learning | pandas-data-analysis | sequential-thinking | python-testing-patterns | clean-code

Descripcion:

Se dividieron los datos en train/test, se aplico escalado, se entreno Logistic Regression como modelo base y se valido con cross-validation. Resultados: Accuracy 0.79, F1 0.57.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking, machine-learning, pandas-data-analysis y clean-code para preparar datos y entrenar modelo base en celdas separadas: CELDA 1: Separacion X e y CELDA 2: train_test_split con stratify=y, test_size=0.2, random_state=42 CELDA 3: StandardScaler (fit en train, transform en ambos) CELDA 4: Logistic Regression con accuracy, precision, recall, F1 y matriz de confusion CELDA 5: cross_val_score cv=5 CELDA 6: Comparacion train vs test, deteccion de overfitting Guardar splits en data/processed/
```

PASO 08 Modelos Avanzados y Optimizacion

Skills utilizados: machine-learning | sequential-thinking | clean-code

Descripcion:

Se entrenaron Random Forest y HistGradientBoosting con SMOTE y class_weight='balanced'. Se optimizaron hiperparametros con GridSearchCV. Mejores parametros RF: max_depth=10, min_samples_split=5, n_estimators=100.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking y machine-learning para la siguiente iteracion del modelo: 1. Aplicar SMOTE para balancear clases en X_train 2. Entrenar Random Forest y XGBoost con class_weight='balanced' 3. Comparar accuracy, precision, recall y F1 en tabla resumen 4. Graficar feature importance del mejor modelo con seaborn 5. Optimizar con GridSearchCV maximizando recall Churn=1 6. Ajustar threshold a 0.3 para maximizar recall 7. Curva ROC-AUC comparativa de los 3 modelos Guardar el mejor modelo en models/
```

PASO 09 Evaluacion Final del Modelo

Skills utilizados: machine-learning | data-analysis-jupyter | statistics-math | sequential-thinking

Descripcion:

Evaluacion completa del Random Forest Optimizado:

- AUC ROC: 0.841 | Logistic Regression: 0.843
- Recall Churn=1 con threshold=0.3: 89.04%
- F1-Score: 0.60 | Falsos Negativos: 41 (10.96%)
- Top features: customer_tenure, account_Charges_Total, account_Charges_Monthly

Prompt utilizado en Claude Code:

```
Usa sequential-thinking, machine-learning y data-analysis-jupyter para evaluacion final: CELDA 1: Curvas ROC comparativas de los 3 modelos CELDA 2: Curva Precision-Recall con punto optimo threshold=0.3 CELDA 3: Analisis de falsos negativos y perfil del cliente no detectado CELDA 4: Feature importance top 15 con seaborn CELDA 5: Classification report + matriz de confusion final Guardar graficos en docs/graficos/
```

PASO 10 Reporte Ejecutivo

Skills utilizados: documentation-writer | sequential-thinking

Descripcion:

Se genero el REPORTE_EJECUTIVO.md con resumen del problema, metodologia, resultados finales, top 5 insights del negocio y recomendaciones de implementacion.

Prompt utilizado en Claude Code:

```
Usa sequential-thinking y documentation-writer para crear el reporte final del proyecto: 1. Resumen del problema y objetivo 2. Metodologia aplicada (pipeline completo) 3. Resultados finales del modelo 4. Top 5 insights del negocio 5. Recomendaciones de implementacion Guardar como REPORTE_EJECUTIVO.md
```

PASO 11 Validacion del Script de Inferencia

Skills utilizados: machine-learning | sequential-thinking

Descripcion:

Se probó app/predict.py con los datos reales del proyecto. Resultados:

- 5 clientes analizados, 3 en riesgo (60%)
- 100% de clientes en riesgo con contrato Month-to-month
- Top cliente: 9237-HQITU con 83.05% de probabilidad de Churn
- Pipeline certificado para produccion

Prompt utilizado en Claude Code:

```
Usa machine-learning y sequential-thinking para probar app/predict.py: 1. Revisar que datos de entrada espera predict.py 2. Cargar churn_model_rf_optimized.joblib y scaler.joblib 3. Aplicar mismo pipeline de preprocesamiento del entrenamiento 4. Ejecutar predicciones con threshold=0.3 5. Comparar con data/processed/clientes_en_riesgo_2025.csv 6. Generar resumen: total clientes, % riesgo, distribucion por contrato 7. Exportar a
```

Resumen de Skills Utilizados por Etapa

Paso	Etapas	Skills Principales
01	Configuración	token-optimizer, context-window-management, sequential-thinking
02	Calidad de Datos	data-analysis, read-file, sequential-thinking
03	EDA Gráficos	data-analysis-jupyter, statistics-math, sequential-thinking
04	Feature Engineering	pandas-data-analysis, clean-code, sequential-thinking
05	Correlación	statistics-math, pandas-data-analysis, data-analysis-jupyter
06	Visualización Churn	data-analysis-jupyter, statistics-math, data-analysis
07	Modelo Base	machine-learning, python-testing-patterns, clean-code
08	Modelos Avanzados	machine-learning, sequential-thinking, clean-code
09	Evaluación Final	machine-learning, data-analysis-jupyter, statistics-math
10	Reporte Ejecutivo	documentation-writer, sequential-thinking
11	Inferencia	machine-learning, sequential-thinking

Resultados Finales del Modelo

Métrica	Valor	Descripción
AUC-ROC	0.841	Excelente capacidad de discriminación
Recall Churn=1	89.04%	Detecta 9 de cada 10 clientes en riesgo
F1-Score	0.60	Balance aceptable precisión/recall
Falsos Negativos	41 (10.96%)	Churners no detectados
Threshold	0.3	Umbral optimizado para maximizar recall
Top Feature	customer_tenure	Variable más determinante del Churn